IE5202

APPLIED FORECASTING METHODS

Lecture 7–12 考前复习讲义

讲义知识点 · 完整公式 · 图像识别 · 易错陷阱 · 六道 ACF/PACF 练习

使用说明 / Reading Guide

本讲义按以下课程主题：**Lecture 7 Regression on Time**、**Lecture 8 Exponential Smoothing**、**Lecture 9 ARMA**、**Lecture 10 ARIMA/SARIMA**、**Lecture 11 RNN/LSTM**、**Lecture 12 Transformer** 组织。公式沿用课堂记号；个别软件的 MA 符号约定不同会特别说明。**图像题是重中之重**，公开版不包含教师课件原图及官方试题原文；保留独立模拟的 Q1–Q6 识图练习。

章节	主题与必考动作	强调
L7	时间回归、预测区间、DW、季节虚拟变量/Fourier、增长曲线	模型辨析
L8	SES、Holt、Holt–Winters 加法/乘法、SSE、区间	递推计算
L9	平稳性、SAC/SPAC、ACF/PACF、AR/MA/ARMA、后移算子	识图重点
L10	ARIMA/SARIMA、差分、季节滞后、模型检验、酒店案例	识图重点
L11	NNAR、RNN、BPTT、LSTM/GRU、预测与诊断	门控与梯度
L12	激活函数、TCN、Seq2Seq、Attention、Transformer、前沿方法	结构与公式

考前最优学习顺序

先看 L9–L10 的 ACF/PACF 截尾、季节 lag 12 识别、酒店 SARIMA 和 Q1–Q6，再掌握 L7–L8 的递推/区间；最后集中记 L11–L12 的网络结构、门控机制、Attention 公式及预测策略。**所有图像识别只能给出候选模型，不能取代残差检验**。

目录

1 Lecture 7 · Regression on Time **3**

1.1 时间回归：用 t 解释趋势 . . . 3
1.2 点预测 vs 区间预测；宽度从哪里来？ . . . 3
1.3 残差自相关与 Durbin–Watson (DW) . . . 3
1.4 季节性：加法/乘法，Dummy/Fourier . . . 4
1.5 非线性增长：先看能否变成线性回归 . . . 4

2 Lecture 8 · Exponential Smoothing **5**

2.1 为什么需要指数平滑？ . . . 5
2.2 SES：Simple Exponential Smoothing（无明显趋势与季节） . . . 5
2.3 Holt：同时平滑 Level 与 Trend . . . 5
2.4 Holt–Winters：加入季节性 . . . 6
2.5 模型选择、预测区间、和 ARIMA 的对应关系 . . . 6

3 Lecture 9 · ARMA / Box–Jenkins 7
3.1 平稳性、ACF/SAC 和 PACF/SPAC：先懂图的含义 . . . 7
3.2 MA(q)：随机冲击的有限记忆 . . . 7
3.3 AR(p)：观测值的有限直接记忆 . . . 7
3.4 ARMA(p,q)、后移算子与可逆性 . . . 8

4 Lecture 9–10 特别专题 · ACF/PACF 六道识图题 9

5 Lecture 10 · ARIMA, SARIMA and Model Diagnostics 12
5.1 差分、单位根、平稳性/可逆性 . . . 12
5.2 ARIMA 多步预测：未来误差取 0，预测后要逆差分 . . . 12
5.3 估计、模型选择、残差检验 . . . 12
5.4 季节 ARIMA 记号与乘法结构 . . . 13
5.5 Hotel Room Demand：案例分析与候选模型选择 . . . 13
5.6 Regression with ARMA Errors：连接 Lecture 7 . . . 14

6 Lecture 11 · Neural Networks, RNN and LSTM 15
6.1 从 AR(p) 到监督学习：窗长 p 就是输入维度 . . . 15
6.2 RNN：保留隐藏状态，而不是固定窗口的全部原始值 . . . 15
6.3 BPTT 和梯度消失 / 爆炸 . . . 15
6.4 LSTM：Cell State 的加法记忆通道 . . . 16
6.5 GRU：更简化的门控单元 . . . 16
6.6 神经网络预测、残差和区间 . . . 16

7 Lecture 12 · Attention, Transformers and Beyond 17
7.1 课程数据与神经预测的统一前处理 . . . 17
7.2 Activation functions：选择输出值的范围 . . . 17
7.3 TCN：Causal Dilated Convolution . . . 17
7.4 Seq2Seq：Encoder–Decoder 与 Teacher Forcing . . . 18
7.5 Seq2Seq Attention：解除单一 context bottleneck . . . 18
7.6 Transformer：Q / K / V 和 Causal Mask . . . 18
7.7 Minimal Transformer：一个 Attention Head 究竟学什么？ . . . 19
7.8 常见 Time-Series Deep Models：知道分别解决什么 . . . 19

8 六章跨章节综合速查 20
8.1 方法之间的内在联系（最易考概念题） . . . 20
8.2 考前五分钟：识图 + 易错公式 . . . 20

9 Original Practice Questions / 原创练习题 21

附录：英文术语考前速查表 23

1 Lecture 7 · Regression on Time

1.1 时间回归：用 t 解释趋势

讲义基准式 $y_t = TR_t + \epsilon_t$：Trend 是可由时间解释的系统变化；ϵ_t 是剩余误差。截距项不能被误解为“第 0 期一定实际存在”。

核心公式与判别

$$\text{No trend: } TR_t = \beta_0$$
$$\text{Linear: } y_t = \beta_0 + \beta_1 t + \epsilon_t$$
$$\text{Quadratic: } y_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \epsilon_t$$

线性趋势斜率固定为 β_1；二次趋势的局部变化率是 $\beta_1 + 2\beta_2 t$，$\beta_2 < 0$ 意味着曲线逐渐向下弯，不一定表示全部时期都在下降。

课堂 Calculator Sales：$\hat{y}_t = 198.029 + 8.0743t$，预测第 25 期为 $198.029 + 8.0743 \times 25$。课堂 Loan Requests：$\hat{y}_t = 199.62 + 50.937t - 0.5677t^2$；二次项允许增长速度改变。

Figure omitted in public edition: see the adjacent conceptual explanation.

1.2 点预测 vs 区间预测；宽度从哪里来？

给定线性回归，$\hat{y}_{t_*} = \hat{\beta}_0 + \hat{\beta}_1 t_*$。讲义单个**新观测值**的预测区间：

$$\hat{y}_{t_*} \pm t_{1-\alpha/2,n-2}\, s\sqrt{1 + h_{t_*}}, \quad h_{t_*} = \frac{1}{n} + \frac{(t_* - \bar{t})^2}{\sum_{i=1}^{n}(t_i - \bar{t})^2}$$

其中 $s = \sqrt{SSE/(n-2)}$（线性回归）；h 是杠杆值。预测越远离 $\bar{t}$，区间越宽。对均值的confidence interval不带根号内的“1”；对新观测的prediction interval 带“1”。多元/二次回归须用相应的 $\mathbf{x}_*^\top (X^\top X)^{-1}\mathbf{x}_*$ 和残差自由度 $n-k$，不能机械照搬简单线性回归的 $n-2$。

Figure omitted in public edition: see the adjacent conceptual explanation.

1.3 残差自相关与 Durbin–Watson (DW)

回归误差独立的假设若失效，常规标准误与 t/F 检验可能不可靠。First-order autocorrelation: $\epsilon_t = \phi\epsilon_{t-1} + a_t$；$\phi > 0$ 正相关，$\phi < 0$ 负相关。

$$DW = d = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t^2} \approx 2(1 - r_1)$$

$d \approx 0$	强正自相关	相邻残差相近
$d \approx 2$	无明显一阶自相关	H_0 倾向不拒绝
$d \approx 4$	强负自相关	正负交替

课堂双侧 DW 判别：$d < d_L$ 或 $4 - d < d_L$ 则拒绝 H_0；两端均大于 d_U 则不拒绝；落在 d_L, d_U 的不确定带则 **inconclusive**。单侧正相关看 d 是否小，负相关看 $4 - d$ 是否小。精确 d_L, d_U 取决于 n、自变量数、显著性水平。

易错点提醒

DW 不是 r_1；$d = 2$ 才对应近似无一阶自相关。DW 的“不确定区间”不可强行判定。DW 主要检验一阶残差自相关，不是全面的白噪声检验；L10 用 Ljung–Box 检验多个滞后阶。

1.4 季节性：加法/乘法，Dummy/Fourier

加法季节：$y_t = TR_t + SN_t + \epsilon_t$，季节振幅大致恒定；乘法季节：$y_t \simeq TR_t \times SN_t \times \epsilon_t$，振幅随水平变大，常取 $x_t = \log y_t$ 转成近似加法形式。

Figure omitted in public edition: see the adjacent conceptual explanation.

Dummy Variables（季节虚拟变量）：周期 L，含截距时用 $L-1$ 个虚拟变量避免dummy variable trap：

$$y_t = \beta_0 + \beta_1 t + \sum_{j=1}^{L-1} \gamma_j D_{j,t} + \epsilon_t.$$

被省略的季节是**参考组**；γ_j 表示相对参考季节的差异。**Fourier / Trigonometric**：

$$\boxed{SN_t = \sum_{k=1}^{K} \left[a_k \sin\left(\frac{2\pi k t}{L}\right) + b_k \cos\left(\frac{2\pi k t}{L}\right) \right]}$$

每个频率需要 sin/cos 成对；周期 $L = 12$ 的一阶谐波是 $2\pi t/12$；高次谐波刻画更复杂的季节形状。多个 dummy 适合任意季度/月度固定效应，Fourier 用较少参数表示平滑周期性。

1.5 非线性增长：先看能否变成线性回归

核心公式与判别

$$y_t = \beta_0 \beta_1^t \epsilon_t \quad \Longrightarrow \quad \log y_t = \log \beta_0 + t \log \beta_1 + \log \epsilon_t.$$

β_1 是每期增长倍数，增长率为 $\beta_1 - 1$；若模型写 $y_t = \beta_0 e^{bt} \epsilon_t$，增长率为 $e^b - 1$。

讲义另列 modified exponential $s + \alpha e^{\beta t}$、Gompertz $s \exp(\alpha e^{\beta t})$、Logistic $s/(1 + \alpha e^{ct})$，共同特征为可以描述增速变化或饱和；logistic 的 s 通常是上限（具体需满足参数符号条件）。

Figure omitted in public edition: see the adjacent conceptual explanation.

易错点提醒

不要把“有曲线”直接等于二次趋势；趋势回归的系数是确定的，不随时间自动更新。乘法季节变化先考虑 log；指数增长取 log 后的回归误差定义已发生变化。预测**原尺度均值**时，直接 $e^{\widehat{\log y}}$ 可能存在反变换偏差。

2 Lecture 8 · Exponential Smoothing

2.1 为什么需要指数平滑？

L7 的趋势/季节参数固定；L8 则允许近期数据逐渐更新 level、trend、seasonality。**权重随历史远近呈指数衰减**，不是所有期同权。

2.2 SES：Simple Exponential Smoothing（无明显趋势与季节）

核心公式与判别

$$\boxed{L_t = \alpha y_t + (1-\alpha)L_{t-1} = L_{t-1} + \alpha(y_t - L_{t-1})}$$

$$\hat{y}_{t+h|t} = L_t,\ h \geq 1; \qquad 0 < \alpha < 1.$$

展开：$L_t = \alpha y_t + \alpha(1-\alpha)y_{t-1} + \cdots + (1-\alpha)^t L_0$。

α 大：新观测权重大、响应快、曲线抖动大；α 小：平滑强、响应慢。初始值 L_0 需要设定或优化。一步误差 $e_t = y_t - L_{t-1}$；通过最小化 $SSE = \sum_t e_t^2$ 选择 α。

考题模式 / 快速识别

若 $L_{t-1} = 100, y_t = 110, \alpha = 0.3$，则 $L_t = 0.3(110) + 0.7(100) = 103$。无论 $h = 1, 2, \ldots$，SES 点预测均为 103，不是每远一步都再加 3。

课堂 SES 预测区间近似：$L_n \pm z_{0.025} s\sqrt{1 + (h-1)\alpha^2}$，$s = \sqrt{SSE/(n-1)}$。注意这是特定误差假设下的课堂表达。

Figure omitted in public edition: see the adjacent conceptual explanation.

2.3 Holt：同时平滑 Level 与 Trend

核心公式与判别

$$\begin{aligned} L_t &= \alpha y_t + (1-\alpha)(L_{t-1} + B_{t-1}), \\ B_t &= \gamma(L_t - L_{t-1}) + (1-\gamma)B_{t-1}, \\ \hat{y}_{t+h|t} &= L_t + hB_t. \end{aligned}$$

一步预测误差 $e_t = y_t - (L_{t-1} + B_{t-1})$；误差修正形式：

$$L_t = L_{t-1} + B_{t-1} + \alpha e_t, \quad B_t = B_{t-1} + \alpha\gamma e_t.$$

L_t 为更新的水平，B_t 为更新斜率。课程用 γ 表示斜率平滑参数；有些 Python 包或教材以 β 命名。

考题模式 / 快速识别

假设 $L_{t-1} = 50, B_{t-1} = 3, y_t = 55, \alpha = 0.4, \gamma = 0.2$：先算 $e_t = 55 - 53 = 2$；$L_t = 53 + 0.4 \cdot 2 = 53.8$；$B_t = 3 + 0.4 \cdot 0.2 \cdot 2 = 3.16$；两步预测 $L_t + 2B_t = 60.12$。

课堂 Holt 的区间：

$$\hat{y}_{n+h} \pm z_{0.025} s \sqrt{1 + \sum_{j=1}^{h-1} \alpha^2(1+j\gamma)^2}, \quad s = \sqrt{SSE/(n-2)}.$$

Figure omitted in public edition: see the adjacent conceptual explanation.

2.4 Holt–Winters：加入季节性

Additive HW（季节波动幅度大致恒定），周期 L：

$$\begin{aligned} L_t &= \alpha(y_t - S_{t-L}) + (1-\alpha)(L_{t-1} + B_{t-1}), \\ B_t &= \gamma(L_t - L_{t-1}) + (1-\gamma)B_{t-1}, \\ S_t &= \delta(y_t - L_t) + (1-\delta)S_{t-L}, \\ \hat{y}_{t+h|t} &= L_t + hB_t + S_{t+h-kL}. \end{aligned}$$

这里 k 选择使季节下标落在最后一个已知完整周期内。**Multiplicative HW**（季节振幅随水平变化）：

$$\begin{aligned} L_t &= \alpha(y_t/S_{t-L}) + (1-\alpha)(L_{t-1} + B_{t-1}), \\ B_t &= \gamma(L_t - L_{t-1}) + (1-\gamma)B_{t-1}, \\ S_t &= \delta(y_t/L_t) + (1-\delta)S_{t-L}, \\ \hat{y}_{t+h|t} &= (L_t + hB_t)\, S_{t+h-kL}. \end{aligned}$$

Figure omitted in public edition: see the adjacent conceptual explanation.

核心公式与判别

HW error-correction form（讲义原式，加法季节）：

$$E_t = y_t - (L_{t-1} + B_{t-1} + S_{t-L}),$$

$$L_t = L_{t-1} + B_{t-1} + \alpha E_t, \qquad B_t = B_{t-1} + \alpha\gamma E_t,$$

$$S_t = S_{t-L} + (1-\alpha)\delta E_t.$$

2.5 模型选择、预测区间、和 ARIMA 的对应关系

常见选择：无趋势无季节 → SES；趋势但无季节 → Holt；趋势加季节 → HW。通过训练期 SSE/验证集误差选择平滑参数，用测试集检查外推。L10 告诉我们 SES 与 $ARIMA(0,1,1)$ 相联系，Holt 与 $ARIMA(0,2,2)$ 相联系（参数和初始化需匹配）。

易错点提醒

(1) L_t 是 **level**，不要与季节周期 L 混淆。**(2)** Additive 预测用加号，Multiplicative 用乘号；季节因子不是趋势系数。**(3)** Holt 是水平 + 斜率两次更新；HW 是水平/斜率/季节三次更新。**(4)** MA(q) 模型（L9）并不是简单移动平均（L8）。**(5)** 对照课件的预测区间公式时，检查用的是绝对误差还是相对误差。

3 Lecture 9 · ARMA / Box–Jenkins

3.1 平稳性、ACF/SAC 和 PACF/SPAC：先懂图的含义

Weak stationarity：$E(y_t)=\mu$ 不随 t 变化，$\mathrm{Var}(y_t)=\sigma_y^2$ 固定，$\mathrm{Cov}(y_t,y_{t-k})$ 只取决于 lag k。趋势、随机游走和未消除的明显季节性可能导致不平稳。White noise：$E\epsilon_t=0$，$\mathrm{Var}(\epsilon_t)=\sigma^2$，不同时间不相关。

核心公式与判别

$$\gamma_k=\mathrm{Cov}(y_t,y_{t-k}),\qquad \rho_k=\frac{\gamma_k}{\gamma_0};\qquad r_k=\frac{\sum_{t=k+1}^{n}(y_t-\bar{y})(y_{t-k}-\bar{y})}{\sum_{t=1}^{n}(y_t-\bar{y})^2}.$$

ACF (theoretical) / SAC (sample)：滞后 k 的总线性相关（包含间接影响）。PACF / SPAC：控制中间 $k-1$ 个滞后后的直接线性关联；PACF(1) =ACF(1)。

例如 AR(1) $y_t=0.8y_{t-1}+\epsilon_t$：$\rho_1=0.8,\rho_2=0.64,\rho_3=0.512$，但 $PACF(2)=PACF(3)=0$（理论意义）。样本图中的零不必精确等于 0；看是否超出 $\pm1.96/\sqrt{n}$ 近似界限（白噪声假设下）。$lag=0$ 的 ACF 恒为 1，**识别模型时不计入**。

3.2 MA(q)：随机冲击的有限记忆

本课 MA 的符号约定是**加号**：

$$y_t=\delta+\epsilon_t+\theta_1\epsilon_{t-1}+\cdots+\theta_q\epsilon_{t-q}.$$

因为 y_t 和 y_{t-k} 只有当 $k\le q$ 时共享误差项，故：

$$\boxed{MA(q):\quad \rho_k=0\ (k>q)\quad\Longrightarrow\quad \text{ACF cuts off at } q.}$$

$$MA(1):\quad \rho_1=\frac{\theta_1}{1+\theta_1^2},\quad \rho_k=0\ (k\ge 2),$$
$$MA(2):\quad \rho_1=\frac{\theta_1(1+\theta_2)}{1+\theta_1^2+\theta_2^2},\quad \rho_2=\frac{\theta_2}{1+\theta_1^2+\theta_2^2}.$$

Figure omitted in public edition: see the adjacent conceptual explanation.

Figure omitted in public edition: see the adjacent conceptual explanation.

易错点提醒

MA(q) 的 q 是**冲击滞后阶数**，不是直接引用过去 q 个 y；MA(1) 的 $|\rho_1|\le 0.5$（可逆边界附近取极限）。不同教材和软件的 MA 项可用负号，不可把系数符号不加转换地移植。

3.3 AR(p)：观测值的有限直接记忆

$$y_t=\delta+\phi_1y_{t-1}+\cdots+\phi_py_{t-p}+\epsilon_t.$$

$$\boxed{AR(p):\quad PACF(k)=0\ (k>p)\quad\Longrightarrow\quad \text{PACF cuts off at } p.}$$

AR(1) 的 ACF 为 $\rho_k=\phi_1^k$：$0<\phi_1<1$ 单调递减；$-1<\phi_1<0$ 正负交替递减。AR(2) 的 ACF 可以是damped oscillation（阻尼振荡），但 PACF 仍在 lag 2 后截尾。

Figure omitted in public edition: see the adjacent conceptual explanation.

Figure omitted in public edition: see the adjacent conceptual explanation.

3.4 ARMA(p,q)、后移算子与可逆性

$$y_t = \delta + \sum_{i=1}^{p} \phi_i y_{t-i} + \epsilon_t + \sum_{j=1}^{q} \theta_j \epsilon_{t-j}.$$

Backshift：$\mathcal{B}y_t = y_{t-1}$，$\mathcal{B}^k y_t = y_{t-k}$。定义：

$$\phi(\mathcal{B}) = 1 - \phi_1\mathcal{B} - \cdots - \phi_p\mathcal{B}^p, \qquad \theta(\mathcal{B}) = 1 + \theta_1\mathcal{B} + \cdots + \theta_q\mathcal{B}^q.$$

$$\boxed{\phi(\mathcal{B})y_t = \delta + \theta(\mathcal{B})\epsilon_t.}$$

纯 AR 的 ACF 拖尾、PACF 截尾；纯 MA 恰好相反；**通常 ARMA 两者都拖尾**，需进一步候选比较。AR(1) 平稳条件 $|\phi_1| < 1$；MA(1) 可逆条件 $|\theta_1| < 1$。一般 AR/MA 多项式在 z 平面对应的根需在单位圆**外**（模 > 1）；MA 可逆确保误差可由观测反推。

Figure omitted in public edition: see the adjacent conceptual explanation.

Lecture 9 截尾/拖尾识别：背下整张表

模型	ACF / SAC	PACF / SPAC
$AR(p)$	拖尾（可能振荡）	**在 p 后截尾**
$MA(q)$	**在 q 后截尾**	拖尾
$ARMA(p,q)$	通常拖尾	通常拖尾

易错点提醒

(1) 不要把 AR 和 MA 截尾位置记反；**(2)** PACF(1)=0.8 说的是 lag=1 的部分自相关为 0.8，不是“PACF 只有 0.8 个滞后”；**(3)** 孤立样本尖峰不代表理论截尾规律失效；**(4)** ARMA 双拖尾不能唯一反推 (p, q)；**(5)** 分析 ACF/PACF 前须先处理非平稳（L10）。

4 Lecture 9–10 特别专题 · ACF/PACF 六道识图题

看图四步，不需要背六张图

(1) 看 lag 0 以外的柱子是否越过置信带；(2) 看 ACF 是否有明确截尾；(3) 看 PACF 是否有明确截尾；(4) 有季节时单独看 $L, 2L, 3L$。“截尾”是理论规律，样本中表现为截尾点之后**绝大部分**柱子不显著。

Q1：AR(1) · PACF lag 1 截尾

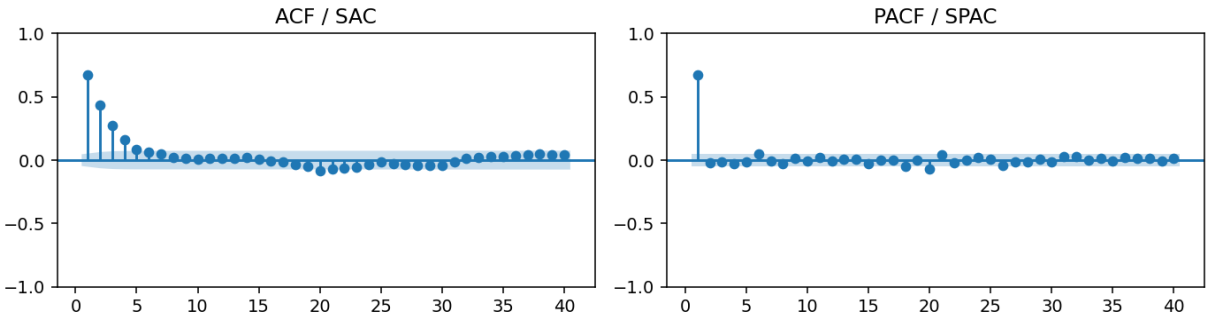


图 1: 模拟识图 Q1：ACF 逐渐衰减；PACF 主要只有 lag 1 显著。

答案： $AR(1)$。顺序：PACF 在 lag 1 后基本落入置信区间 $\Rightarrow p = 1$；ACF 拖尾。**不要**因 ACF lag 2、3 仍有正柱子误判为 AR(3)：它们可以是 lag 1 传递的间接相关。

Q2：MA(2) · ACF lag 2 截尾

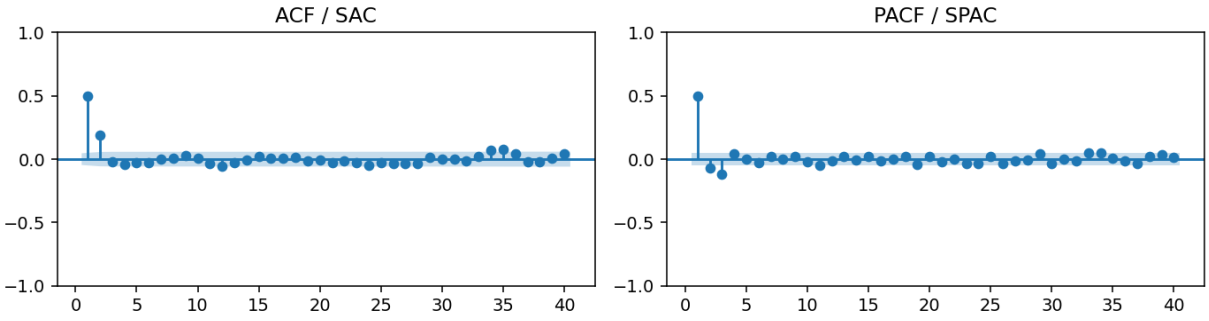


图 2: 模拟识图 Q2：ACF 在 lag 1、2 有系统相关，之后基本不显著；PACF 拖尾。

答案： $MA(2)$。先看左图截尾位置 $q = 2$，而不是根据右图偶尔的显著柱子随便增大 p。**关键**：MA 项是过去的随机误差 ϵ_{t-j}。

Q3：AR(2) · ACF 阻尼振荡

答案： $AR(2)$。**关键陷阱**：ACF 拖尾可以上下振荡，不必永远正且单调下降。判断阶数依旧以 PACF 截尾点为准。

Q4：ARMA(1,1) · 双拖尾

答案： 本题设计时使用 $ARMA(1,1)$；在**真实考试中**，双拖尾只够支持“优先考虑 ARMA 类候选”，不一定能唯一确定 $(1,1)$。需要 AIC/BIC、残差诊断、预测比较。

Q5：季节 AR(1) · 只看季节 PACF

答案： $SARIMA(0,0,0)(1,0,0)_{12}$。因为**季节 PACF 在 12 截尾** $\Rightarrow P = 1$；季节 ACF 在 12、24、36 拖尾。$P = 1$ 对应直接使用 y_{t-12}，**不是** y_{t-1}。

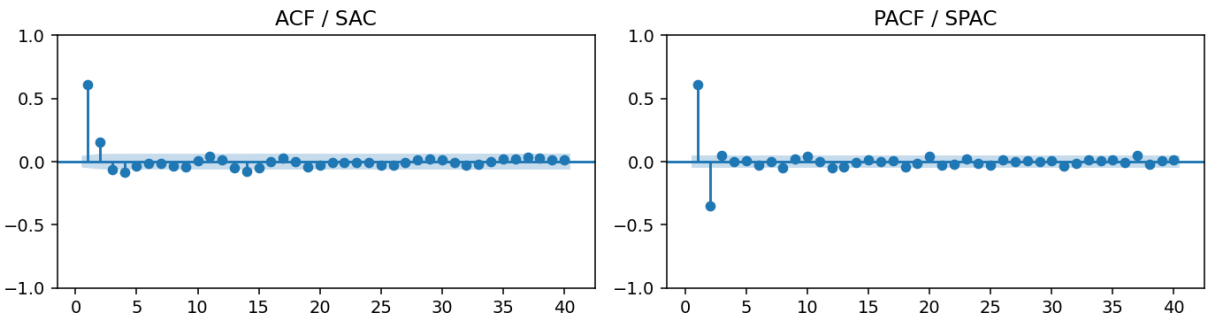


图 3: 模拟识图 Q3：ACF 正负交替且逐渐衰减；PACF 到 lag 2 截尾。

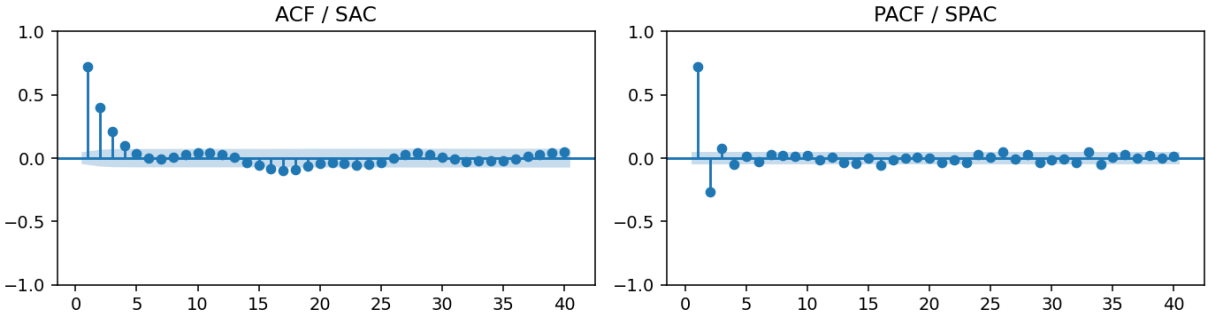


图 4: 模拟识图 Q4：ACF/PACF 均拖尾；来源模型为 ARMA(1,1)。

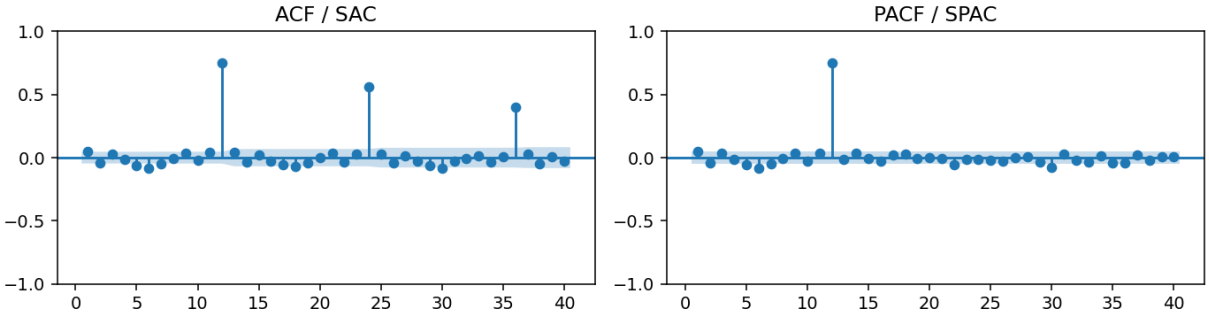


图 5: 模拟识图 Q5：月度平稳数据，PACF 季节 lag 12 截尾，ACF 季节位置逐渐衰减。

Q6：季节 MA(1) · 只看季节 ACF

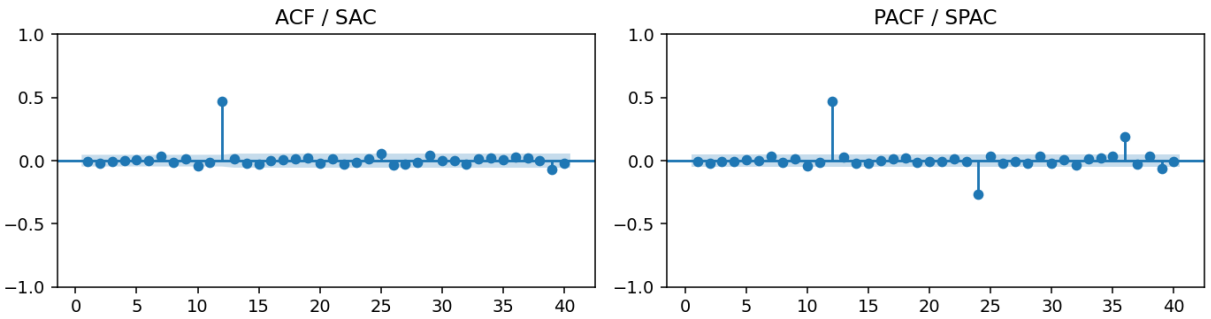


图 6: 模拟识图 Q6：月度平稳数据，ACF 季节 lag 12 截尾，PACF 季节位置逐渐衰减。

答案： $SARIMA(0,0,0)(0,0,1)_{12}$。因为**季节 ACF 在 12 截尾** $\Rightarrow Q=1$。lag 12 系数的负号或正号表示相关方向，而**不是**季节阶数为负。

六题之后的终极提醒

L9 识图主要求 p,q；L10 SARIMA 在已做必要差分之后还要求 P,Q。但是 d,D **不是从 "ACF 截尾于几阶" 直接读出的**，要对原始序列和差分序列比较后决定。季节位置出现 11、13 的旁瓣还可能来自普通与季节 MA 多项式乘积。

5 Lecture 10 · ARIMA, SARIMA and Model Diagnostics

5.1 差分、单位根、平稳性/可逆性

Random walk: $y_t = y_{t-1} + \epsilon_t$，AR 系数为 1，存在unit root，方差随时间增长。一阶差分使之成为 $\Delta y_t = \epsilon_t$，即 $ARIMA(0,1,0)$。

核心公式与判别

$$\begin{aligned}\Delta y_t &= (1-\mathcal{B})y_t = y_t - y_{t-1},\\ \Delta^2 y_t &= (1-\mathcal{B})^2 y_t = y_t - 2y_{t-1} + y_{t-2},\\ \Delta_L y_t &= (1-\mathcal{B}^L)y_t = y_t - y_{t-L},\\ \Delta\Delta_L y_t &= y_t - y_{t-1} - y_{t-L} + y_{t-L-1}.\end{aligned}$$

$ARIMA(p,d,q)$ 表示**差分** d **次后的序列**满足 ARMA(p,q)；$\phi(\mathcal{B})(1-\mathcal{B})^d y_t = \delta + \theta(\mathcal{B})\epsilon_t$。$d=0$ 不是必须差分；$d=2$ 也不是“使用 lag 2 的观测值”。**ADF** 原假设有单位根，p 小支持拒绝单位根；**KPSS** 原假设平稳，p 小则反对平稳。结合时序图/ACF 判断，注意小样本功效和检验版本。**过度差分**：在已平稳序列上继续差分可能制造强的 lag 1 负相关（常见约 -0.5）。

易错点提醒

对 AR(1) $y_t = \phi y_{t-1} + \epsilon_t$，$|\phi| < 1$ 是平稳条件；$\phi = 1$ 是单位根。一般 AR 的特征根在单位圆**外**。软件 `statsmodels` 可能显示 MA 项为加号，本讲义也用加号；另一部分教材用负号，比较 α 与 MA 系数时必须先统一约定。

5.2 ARIMA 多步预测：未来误差取 0，预测后要逆差分

条件点预测遵循：已知历史值用实际值，未来未知 y 用先前预测值，未来 ϵ 的条件期望为 0。例如：

$$y_t = 10 + 0.6y_{t-1} + \epsilon_t + 0.4\epsilon_{t-1} \implies \hat{y}_{t+1|t} = 10 + 0.6y_t + 0.4\hat{\epsilon}_t.$$

若 $z_t = y_t - y_{t-1}$，则 $\hat{y}_{t+h|t} = \hat{y}_{t+h-1|t} + \hat{z}_{t+h|t}$（递推、已知取真实值）。

d	长期点预测典型形状	预测误差标准差（典型阶数）
0	回到均值（平稳 ARMA）	趋于常数
1，无 drift	逐渐平坦	$O(\sqrt{h})$
1，有 drift	长期线性	$O(\sqrt{h})$
2	继续线性趋势	$O(h^{3/2})$

5.3 估计、模型选择、残差检验

Moment method：匹配 TAC 与 SAC，AR(1) $\hat{\phi} \simeq r_1$；MA(1) 解 $r_1 = \theta/(1+\theta^2)$ 时要选择**可逆根**。**Least squares**：最小化一步误差 $SSE = \sum(y_t - \hat{y}_{t|t-1})^2$。**MLE**：最大化观测序列的似然。

$$\boxed{AIC = -2\log\hat{L} + 2k, \qquad BIC = -2\log\hat{L} + k\log n}$$

AIC/BIC **越小越好**；BIC 随 n 增大倾向较简单模型。**同一响应变量、同一数据、可比的似然定义**下比较；不同差分/变换时不应直接机械比较程序打印的值。Residual diagnostics: $e_t = y_t - \hat{y}_{t|t-1}$。合格模型剩余误差应近似白噪声。**RSAC/RSPAC** 检查残差结构；Ljung–Box：

$$\boxed{Q^* = n'(n'+2)\sum_{\ell=1}^{K}\frac{r_\ell(e)^2}{n'-\ell} \overset{H_0}{\approx} \chi^2_{K-p-q-P-Q}}$$

H_0：到考察滞后 K 为止残差无自相关；**p 小（如 <0.05）拒绝**，模型可能不足；p 大只是未发现显著残差相关，并非证明模型真。还检查残差方差稳定与 Q–Q 图。

5.4 季节 ARIMA 记号与乘法结构

核心公式与判别

$$\boxed{SARIMA(p,d,q)(P,D,Q)_L}$$

$$\phi_p(\mathcal{B})\Phi_P(\mathcal{B}^L)(1-\mathcal{B})^d(1-\mathcal{B}^L)^D y_t = \delta + \theta_q(\mathcal{B})\Theta_Q(\mathcal{B}^L)\epsilon_t.$$

普通项滞后 1、2、3；季节项滞后 $L, 2L, 3L$。月度 $L=12$，季度 $L=4$。

组件	识别图像	代表解释
Regular AR(p)	PACF 普通滞后于 p 截尾	$y_{t-1},\dots,y_{t-p}$
Regular MA(q)	ACF 普通滞后于 q 截尾	$\epsilon_{t-1},\dots,\epsilon_{t-q}$
Seasonal AR(P)	PACF 季节滞后于 PL 截尾	$y_{t-L},\dots,y_{t-PL}$
Seasonal MA(Q)	ACF 季节滞后于 QL 截尾	$\epsilon_{t-L},\dots,\epsilon_{t-QL}$

Airline model $SARIMA(0,1,1)(0,1,1)_{12}$：

$$(1-\mathcal{B})(1-\mathcal{B}^{12})y_t = (1+\theta\mathcal{B})(1+\Theta\mathcal{B}^{12})\epsilon_t,$$
$$y_t - y_{t-1} - y_{t-12} + y_{t-13} = \epsilon_t + \theta\epsilon_{t-1} + \Theta\epsilon_{t-12} + \theta\Theta\epsilon_{t-13}.$$

Cross term $\theta\Theta\epsilon_{t-13}$ 不是自由的 MA(13) 系数。普通/季节 MA 乘积可在 lag $L\pm1$ 形成side-lobes；不要看到 lag 13 就认定 $q=13$。

5.5 Hotel Room Demand：案例分析与候选模型选择

数据：月度 1977–1990，共 168 个点，最后 24 个月作为测试集。原始序列趋势上升且季节振幅变大。先 $x_t=\log y_t$ 稳定季节绝对振幅；再比较不同差分：普通差分无法清除季节 lag 12、24、36 的长相关；只做季节差分效果较好；双重差分有过度差分迹象。于是：

$$\boxed{z_t = (1-\mathcal{B}^{12})\log y_t, \qquad d=0,\ D=1,\ L=12.}$$

Figure omitted in public edition: see the adjacent conceptual explanation.

Figure omitted in public edition: see the adjacent conceptual explanation.

Figure omitted in public edition: see the adjacent conceptual explanation.

从图到模型：考试最重要的一步

右侧 PACF（SPAC）：普通 lag 1 和 lag 3 重要，lag 3 后普通部分无明确持续结构 ⇒ 初始候选 $p=3$；lag 2 无明显尖峰不排除 AR(3)，且 lag 5 接近边界。**左侧 ACF（SAC）**：lag 12 单个明显负尖峰、之后 lag 24、36 无同样持续季节 ACF 结构 ⇒ 初始候选 $Q=1$。先设 $q=P=0$。所以

$$\boxed{SARIMA(3,0,0)(0,1,1)_{12}.}$$

图中也可能有单个其他显著柱子，**不是数学上完美截尾；这是 tentative model，不是唯一结论**。

拟合：在 z_t 上用 AR(3)+ 季节 MA(1)；讲义季节 MA 系数约 -0.53，常数约 0.027。由于 $z_t=\log y_t-\log y_{t-12}$，若 $E(z_t)\approx0.034$，解释为每年同月对数增长约 3.4%（原尺度 $e^{0.034}-1$）。

Figure omitted in public edition: see the adjacent conceptual explanation.

诊断：RSAC/RS PAC 无明显残余模式，Ljung–Box $p > 0.05$；比较相同变换与差分下的相邻 AR、MA 候选模型：AR(3) AIC 较低，部分简单候选也可能接近。**预测**：先算 $\hat{z}$，再 $\widehat{\log y}_{t+h} = \widehat{\log y}_{t+h-12} + \hat{z}_{t+h}$（对已知历史用真实值），最后逆 log。$\exp(\widehat{\log y})$ 对数正态假设下对应原尺度中位数；均值需 $\exp(\widehat{\log y} + \sigma_h^2/2)$ 修正。

Figure omitted in public edition: see the adjacent conceptual explanation.

易错点提醒

(1) 取 log 主要稳定振幅，**不等于**差分；**(2)** Lag 12 的负峰决定季节 MA 候选方向，不意味着 $Q = -1$；**(3)** $p = 3$ 并不要求 lag 1、2、3 每根 PACF 都显著；**(4)** 测试期必须在训练期之后，不能把测试数据用于选模型；**(5)** 预测区间覆盖率低意味着不确定性被低估。

5.6 Regression with ARMA Errors：连接 Lecture 7

$$y_t = \mathbf{x}_t^\top \boldsymbol{\beta} + \xi_t, \qquad \phi(\mathcal{B})\xi_t = \theta(\mathcal{B})\epsilon_t.$$

回归部分解释确定性趋势、季节或外生变量；ARMA 部分解释**回归残差中仍存在的相关结构**。普通 OLS 在误差自相关时常规标准误可能无效，且没有充分利用误差动态。Deterministic trend/season：固定的时间函数；stochastic trend/season：受到冲击后可永久改变水平/模式。课程酒店案例中回归 +ARMA 误差的预测区间覆盖率曾约为 79%，提醒固定季节结构可能过于刚性。

Box–Jenkins Workflow：通用题目答题模板

Plot → **Transform** → **Difference** → **Identify** → **Estimate** → **Diagnose** → **Select** → **Forecast / Test**。变换考虑 log；差分求 d, D；ACF/PACF 求候选 p, q, P, Q；残差 Ljung–Box 与 AIC/BIC 验证；最后逆差分/逆变换并对照 seasonal naive 与 HW 基线。

6 Lecture 11 · Neural Networks, RNN and LSTM

6.1 从 AR(p) 到监督学习：窗长 p 就是输入维度

AR(p)：$y_t = \delta + \sum_{i=1}^{p} \phi_i y_{t-i} + \epsilon_t$。把历史序列转换为监督学习样本：$\mathbf{x}_t = (y_{t-1}, \ldots, y_{t-p})$，标签 y_t。滑动窗长 p，对于 n 个观测点可构造 $n-p$ 个一步预测样本（无额外留出）。

核心公式与判别

$$\hat{y}_t = b + \mathbf{w}^\top \mathbf{x}_t.$$

单个线性神经元 = 线性 AR(p)：$w_i \leftrightarrow \phi_i$，$b \leftrightarrow \delta$。训练最小化 MSE/SSE；梯度下降 $w \leftarrow w - \eta\, \partial SSE/\partial w$。$\eta$ 是学习率，**不是**平滑常数。

NNAR（Nonlinear autoregression）：隐层 $h_j = \sigma(c_j + \mathbf{w}_j^\top \mathbf{x}_t)$，输出 $\hat{y}_t = b + \sum_j v_j h_j$。若 $\sigma(z) = z$，无论叠多少线性层仍是线性函数；非线性激活使其可表达非对称周期、非线性关系等。神经网络相较 ARMA 多许多参数，小样本更易过拟合，需 **scaling**、训练/验证/测试划分、early stopping。

考题模式 / 快速识别

输入 $[y_{t-1}, y_{t-2}, y_{t-3}]$，输出一个标量预测：这是**一次前向的 NNAR(3)**，不是 RNN；若只有无激活线性层，等价 AR(3)。窗口长 36 并不意味着需要 36 个网络层。

6.2 RNN：保留隐藏状态，而不是固定窗口的全部原始值

核心公式与判别

$$\mathbf{h}_t = \sigma(W\mathbf{h}_{t-1} + U y_t + \mathbf{b}),$$
$$\hat{y}_{t+1} = V\mathbf{h}_t + c.$$

State $\mathbf{h}_t$ 把过去历史压缩进一个向量；W 决定记忆如何延续，U 输入当前新信息，V 将隐藏状态映射为预测。**参数跨时间共享**，不是每一期重估一组全新参数。

Figure omitted in public edition: see the adjacent conceptual explanation.

Linear RNN = SES 的特例：令状态维度为 1、$\sigma(z) = z$、$W = 1-\alpha$、$U = \alpha$、$V = 1$，则 $h_t = (1-\alpha)h_{t-1} + \alpha y_t = L_t$。因此课堂联系：ARIMA$(0,1,1)$ $\leftrightarrow$ SES $\leftrightarrow$ 一维线性 RNN（记得 MA 正负号约定）。**线性状态空间与 ARMA**：展开 $\hat{y}_{t+1} = c' + \sum_{k\geq 0}(VW^kU)y_{t-k}$，其权重 $\psi_k = VW^kU$，相当于无限 AR 线性滤波器；W 的特征值在单位圆内对应稳定遗忘。**不是说任意非线性 RNN 都等价 ARMA**。

6.3 BPTT 和梯度消失 / 爆炸

Backpropagation Through Time（时间反向传播）把 RNN 展开，梯度链式相乘：

$$\frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-k}} = \prod_{j=t-k+1}^{t} \mathrm{diag}(\sigma'(\mathbf{a}_j))W.$$

标量线性情形就是 W^k：$|W| < 1$ 梯度随 k 指数衰减（vanishing gradient），$|W| > 1$ 梯度可能爆炸；前者远期记忆难保留，后者训练不稳定。LSTM/GRU 利用门控和加法状态通路缓解此问题；训练常借助梯度裁剪。

6.4 LSTM：Cell State 的加法记忆通道

核心公式与判别

$$
\begin{aligned}
\mathbf{f}_t &= \text{sigmoid}(W_f\mathbf{h}_{t-1} + U_f x_t + \mathbf{b}_f) && \text{forget gate,}\\
\mathbf{i}_t &= \text{sigmoid}(W_i\mathbf{h}_{t-1} + U_i x_t + \mathbf{b}_i) && \text{input gate,}\\
\tilde{\mathbf{c}}_t &= \tanh(W_c\mathbf{h}_{t-1} + U_c x_t + \mathbf{b}_c) && \text{candidate,}\\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t && \text{cell update,}\\
\mathbf{o}_t &= \text{sigmoid}(W_o\mathbf{h}_{t-1} + U_o x_t + \mathbf{b}_o) && \text{output gate,}\\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t). && \text{hidden state}
\end{aligned}
$$

Figure omitted in public edition: see the adjacent conceptual explanation.

门函数 sigmoid 输出 $(0,1)$ 作为“保留/写入比例”，candidate 使用 tanh 输出 $(-1,1)$；$\odot$ 表示逐元素乘。$\mathbf{f}_t \approx 1$ 时保留旧记忆，≈ 0 时忘掉；$\mathbf{i}_t$ 决定写入多少；$\mathbf{o}_t$ 决定状态向外暴露多少。**LSTM 是自适应 SES**：若 $f_t = 1-\alpha, i_t = \alpha, \tilde{c}_t = y_t$，则 $c_t = (1-\alpha)c_{t-1} + \alpha y_t$。真实 LSTM 的门随时间、数据变化。

6.5 GRU：更简化的门控单元

核心公式与判别

$$
\begin{aligned}
\mathbf{z}_t &= \text{sigmoid}(W_z\mathbf{h}_{t-1} + U_z x_t) && \text{update,}\\
\mathbf{r}_t &= \text{sigmoid}(W_r\mathbf{h}_{t-1} + U_r x_t) && \text{reset,}\\
\tilde{\mathbf{h}}_t &= \tanh\{W(\mathbf{r}_t \odot \mathbf{h}_{t-1}) + U x_t\},\\
\mathbf{h}_t &= (1-\mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t.
\end{aligned}
$$

GRU 不另设 cell state c_t；讲义使用 z_t 作为新 *candidate* 的更新权重，也可写成 $\mathbf{h}_t = \mathbf{h}_{t-1} + \mathbf{z}_t \odot (\tilde{\mathbf{h}}_t - \mathbf{h}_{t-1})$，与 SES 误差修正形式相似。不同教材可能把 GRU 的 z_t 定义为“保留旧状态”的门，**考试照教师公式**。

6.6 神经网络预测、残差和区间

多步预测：recursive（反复预测一步并回填，误差累积），direct（一次输出 H 个 horizon），seq2seq（编码器读历史、解码器逐步输出）。无论网络多复杂，**残差 SAC/SPAC 与 Ljung–Box 仍然适用**。预测区间通常需要distributional head（μ, σ）、quantile loss、ensemble/bootstrap 等；点预测网络不会自动给可信区间。

易错点提醒

(1) RNN 的“长记忆”在理论上无限，但梯度消失让实际长依赖难学；**(2)** f_t 是保留旧 cell state 的比例，**不是**直接输出权重；**(3)** sigmoid 多用于 gates，tanh 多用于 candidate/state；**(4)** LSTM cell state c_t 与 hidden state h_t 不是同一个变量；**(5)** 在短且单一的系列（讲义 sunspots）中，优秀 ARIMA 往往比大网络更稳。

7 Lecture 12 · Attention, Transformers and Beyond

7.1 课程数据与神经预测的统一前处理

讲义使用 Mauna Loa CO_2 月度序列，先比较 seasonal ARIMA 基线，再训练 neural models。给定窗口长 L，预测长 H，常用last-value centering：

$$x_{t,i} = \frac{y_{t-L+i} - y_t}{s}, \qquad \text{target}_h = \frac{y_{t+h} - y_t}{s}.$$

网络预测相对最新水平的变化；输出还原时 $\hat{y}_{t+h} = y_t + s\hat{x}_{t+h}$。零预测相当于 random-walk 基线 $\hat{y}_{t+h} = y_t$。同课 Linear model：$\hat{y}_{t+h} - y_t = \sum_{i=0}^{L-1} w_{h,i}(y_{t-i} - y_t)$，是**每个 horizon 分别预测**的直接线性 AR 类模型；任何深模型都应和此简单基线比较。

7.2 Activation functions：选择输出值的范围

名称	定义 / 范围	用途与陷阱
Identity	$\sigma(z) = z$；全实数	回归预测输出层；连续线性层仍为线性
Sigmoid	$(1 + e^{-z})^{-1} \in (0, 1)$	门控/概率；导数至多 $1/4$，容易饱和
Tanh	$\tanh z \in (-1, 1)$	RNN candidate/state；远离 0 时梯度变小
ReLU	$\max(0, z)$	CNN/深层；$z < 0$ 梯度 0，dead unit
GELU	$z\Phi(z)$	Transformer FFN；平滑 ReLU
Softplus	$\log(1 + e^z) > 0$	标准差/强度等正数输出
Softmax	$p_i = e^{z_i} / \sum_j e^{z_j}$	注意力权重/多分类；和为 1

核心公式与判别

$$\text{sigmoid}'(z) = \text{sigmoid}(z)(1 - \text{sigmoid}(z)), \quad (\tanh z)' = 1 - \tanh^2 z,$$

$$\text{softmax}(z_i/\tau) = \frac{e^{z_i/\tau}}{\sum_j e^{z_j/\tau}}.$$

$\tau \to 0$ 近似选最大 score；$\tau \to \infty$ 近似平均；给全部 score 加同一常数不改变 softmax。SES 的固定衰减权 $\alpha(1-\alpha)^k$ 也可看作某种固定 score 的 softmax。

7.3 TCN：Causal Dilated Convolution

Convolution = backshift polynomial：$z_t = \sum_{j=0}^{k-1} w_j y_{t-jr}$；卷积核宽度 k，膨胀系数 r。普通差分 $(1 - \mathcal{B})$ 相当于核 $(1, -1)$、dilation 1；季节差分 $(1 - \mathcal{B}^{12})$ 对应相同核、dilation 12。**Causal** 表示只允许看 t 及更早，绝不能在时刻 t 使用未来 y_{t+1}（look-ahead leakage）。

核心公式与判别

$$z_t = \sigma\left(b + \sum_{j=0}^{k-1} w_j x_{t-jr}\right), \qquad R = 1 + (k-1)\sum_{\ell=1}^{D} r_\ell.$$

R 是理论receptive field 最大覆盖长度；**不是**保证每一个中间 lag 都可达。若 $k = 2, r = (1, 2, 4, 8)$，$R = 16$；通过二进制求和可覆盖 lag 0–15。

Figure omitted in public edition: see the adjacent conceptual explanation.

讲义另一设计 $r = (1, 2, 4, 12, 24), k = 2$，$R = 44$，但因可达 lag 只能是若干 dilation 之和，lag 8–11、20–23 等可能**无法访问（gridding）**；可扩大核宽、调整 dilation 日程。TCN 能并行训练；RNN 的状态随时间递推，不能像纯卷积那样完全并行。

7.4 Seq2Seq：Encoder–Decoder 与 Teacher Forcing

Encoder 把输入窗口编码为 context **c**；**Decoder** 从 **c** 开始逐步预测 H 期：

$$\mathbf{h}_s = LSTM_{enc}(\mathbf{h}_{s-1}, y_s),\ \mathbf{c} = \mathbf{h}_t, \qquad \mathbf{g}_h = LSTM_{dec}(\mathbf{g}_{h-1}, \hat{y}_{t+h-1}).$$

Figure omitted in public edition: see the adjacent conceptual explanation.

Teacher forcing：训练时把**真实** y_{t+h-1} 输入下一解码步骤，训练稳定；实际预测只能输入**模型预测值**，产生exposure bias（训练与推理不一致）。**Free running**：训练时也回填模型预测值，优化更难但更接近预测时行为。课件 CO_2 实验中 teacher forcing 反而效果较好，说明**不能单靠理论断言 free running 必然更优**。

7.5 Seq2Seq Attention：解除单一 context bottleneck

传统 Seq2Seq 只用固定大小的 **c** 压缩全部历史，长序列信息丢失。Attention 在每个 decoder horizon h 为不同历史 s 计算权重：

核心公式与判别

$$e_{h,s} = \frac{\mathbf{g}_{h-1}^{\top}\mathbf{h}_s}{\sqrt{d}}, \qquad \alpha_{h,s} = \frac{e^{e_{h,s}}}{\sum_u e^{e_{h,u}}}, \qquad \mathbf{c}_h = \sum_s \alpha_{h,s}\mathbf{h}_s.$$

$\alpha_{h,s} \geq 0$，$\sum_s \alpha_{h,s} = 1$；每个预测 horizon 有**自己的** context，而不是共用一根固定向量。

Figure omitted in public edition: see the adjacent conceptual explanation.

比较历史权重：简单 MA 固定等权；SES 固定指数衰减；AR 系数在拟合后固定（可正可负）；Attention 权重随当前输入改变，非负且归一化。注意 **Attention weight 不是 ACF，也不直接等于因果影响大小**。

7.6 Transformer：Q / K / V 和 Causal Mask

Transformer 不再依赖 RNN 按时间递推，使用Self-Attention 计算全体历史位置间的关联：

核心公式与判别

$$\mathbf{q}_t = W_Q\mathbf{x}_t, \qquad \mathbf{k}_s = W_K\mathbf{x}_s, \qquad \mathbf{v}_s = W_V\mathbf{x}_s,$$

$$\boxed{\alpha_{t,s} = \mathrm{softmax}_{s\leq t}\left(\frac{\mathbf{q}_t^{\top}\mathbf{k}_s}{\sqrt{d_k}}\right), \quad \mathbf{z}_t = \sum_{s\leq t}\alpha_{t,s}\mathbf{v}_s.}$$

Q（Query）问要找什么，K（Key）告诉当前位置是否匹配，V（Value）提供被加权读取的信息。$1/\sqrt{d_k}$ 抑制维度增大造成 score 过大与 softmax 过度饱和。

Transformer architecture figure omitted in the public edition.

必备组件：positional encoding（注意力本身不知道时间顺序）、causal mask（不得看未来）、multi-head attention（不同头学习不同相关模式）、residual + LayerNorm + FFN（稳定训练），并行但标准全注意力计算/内存约 $O(L^2)$。

$$PE_{s,2i} = \sin\left(\frac{s}{10000^{2i/d}}\right), \qquad PE_{s,2i+1} = \cos\left(\frac{s}{10000^{2i/d}}\right).$$

Mask 的两类题：在自回归 Decoder，位置 t 只能读 $s \leq t$；在仅以完整历史窗口为输入、直接输出未来的 Encoder-only 预测器，历史窗内部全可见并不一定构成泄漏，重点是**不能包含预测时未知的未来值**。

7.7 Minimal Transformer：一个 Attention Head 究竟学什么？

讲义最小模型：$\mathbf{e}_s = x_s\mathbf{a} + \mathbf{p}_s$，投影成 q, k, v，然后 $\alpha_s = \text{softmax}(q^\top k_s/\sqrt{d})$；多步输出 $\hat{y}_{t+h} = \mathbf{w}_h^\top \sum_s \alpha_s \mathbf{v}_s + b_h$。展开后：

$$\hat{y}_{t+h} = \underbrace{\beta_h \sum_s \alpha_s x_s}_{\text{data-weighted average}} + \underbrace{\sum_s \alpha_s \gamma_{h,s}}_{\text{position-dependent lookup}} + b_h.$$

当输入中心化为 $x_s = (y_s - y_t)/s$ 且当前 $x_t = 0$ 时，讲义进一步写成：

$$\alpha_s = \frac{\pi_s e^{c x_s}}{\sum_u \pi_u e^{c x_u}}, \quad \pi_s = \text{softmax}_s(d_s).$$

它可理解为**固定 lag 偏好 π_s 乘上数据相关的调整项**；图中学习到季节峰值附近的动态注意力，并不意味着 ACF 在同一 lag 也一定最大。

Figure omitted in public edition: see the adjacent conceptual explanation.

7.8 常见 Time-Series Deep Models：知道分别解决什么

模型	最重要的区别/课堂结论
Informer	稀疏 attention，降低长序列成本。
Autoformer	趋势/季节分解 + auto-correlation 跨 lag 聚合。
FEDformer	在频域（Fourier）中建模，减少长序列负担。
DLinear	moving-average 分解为 trend/remainder，两条**线性**预测头后相加。
PatchTST	把连续点合成 patch/token，减少 token 数；学习局部形状。
iTransformer	把**变量**作为 token，在多变量维度建模关联。
N-BEATS	堆叠 basis/backcast/forecast blocks；趋势多项式和季节 Fourier basis。
DeepAR	RNN 输出分布参数 μ_t, σ_t，用概率似然训练，适合多序列。
TFT	LSTM、attention、变量选择、已知未来协变量、分位数输出。
S4 / Mamba	状态空间递推与长卷积相联系；Mamba 引入输入相关选择机制。
Chronos / TimesFM	预训练 time-series foundation models，可零样本迁移。

Figure omitted in public edition: see the adjacent conceptual explanation.

Figure omitted in public edition: see the adjacent conceptual explanation.

DeepAR：$y_{t+1}|\text{past} \sim N(\mu_{t+1}, \sigma_{t+1}^2)$，其中 $(\mu_t, \sigma_t) = g(\mathbf{h}_t)$；通过极大化条件概率训练。**预测区间校准**：95% 区间在测试期应覆盖约 95% 真值；小样本神经概率模型常低覆盖（区间太窄），需要足够数据、分位数训练、校准。

易错点提醒

(1) Attention 是数据相关的归一化权重，既不是 AR 系数也不等于因果解释；**(2)** softmax 对**整组 score** 归一化，sigmoid 对**单个门**映射到 $(0, 1)$；**(3)** 不使用 positional information 的 attention 不天然理解时序顺序；**(4)** $R = 44$ 不代表 TCN 包含所有 44 个滞后；**(5)** 任何网络都应和 SARIMA / DLinear / seasonal naive 比较，而不是仅看训练 MSE；**(6)** 95% 置信度标签并不等于实际 coverage 自动为 95%。

8 六章跨章节综合速查

8.1 方法之间的内在联系（最易考概念题）

古典方法	深度学习对应	相同点 / 差别
AR(p)	线性神经元 / NNAR	同一组 lag 输入；激活函数增加非线性
SES	一维线性 RNN	同样是旧状态的保留 + 新输入的更新
ARMA	线性 RNN / 状态空间	都可表达指数衰减的线性记忆
Fourier seasonal	N-BEATS seasonal basis	用谐波表示周期；前者固定结构
$(1-\mathcal{B}^{12})$	Dilated convolution 12	同样使用季节 lag 12
固定 lag coefficients	Attention	Attention 权重会随样本/预测时间变化
Seasonal ARIMA	Transformer/PatchTST	前者显式建季节 lag；后者需从数据/位置学习或用 patch 编码
ARIMA intervals	DeepAR / quantile network	分别依靠模型误差假设与学习的分布/分位数

8.2 考前五分钟：识图 + 易错公式

识图口诀 / 最终答案卡

AR(p)：PACF 在p 后截尾；ACF 拖尾

MA(q)：ACF 在q 后截尾；PACF 拖尾

ARMA：ACF/PACF 通常均拖尾

Seasonal AR(P)：PACF 季节截尾于PL

Seasonal MA(Q)：ACF 季节截尾于QL

Q1: AR(1)；Q2: MA(2)；Q3: AR(2)；Q4: ARMA(1,1) 候选；Q5: Seasonal AR(1)；Q6: Seasonal MA(1)。

区别题必背

- Confidence interval for *mean* ≠ prediction interval for *new observation*。
- DW $\approx 2(1-r_1)$：近 0 正相关，近 4 负相关。
- Additive vs multiplicative：振幅是否随水平变化。
- SES 一条 level；Holt level+trend；HW 再加季节。
- MA(q) 的误差滞后 ≠ moving average 的等权滑动窗。
- ADF p 小反对单位根；KPSS p 小反对平稳。
- AIC/BIC 小更好；Ljung–Box p 小则怀疑残差未白化。

展开题必背

- $(1-\mathcal{B})^2 y_t = y_t - 2y_{t-1} + y_{t-2}$。
- $(1-\mathcal{B})(1-\mathcal{B}^{12})y_t = y_t - y_{t-1} - y_{t-12} + y_{t-13}$。
- $(1+\theta\mathcal{B})(1+\Theta\mathcal{B}^{12})\epsilon_t$ 包含 $\theta\Theta\epsilon_{t-13}$。
- RNN 长期梯度通过 $\prod W\,\sigma'$，容易消失/爆炸。
- LSTM：$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$。
- Softmax attention：$\alpha \propto e^{q^\top k/\sqrt{d}}$，权重和为 1。
- TCN receptive field：$R = 1 + (k-1)\sum r_\ell$，还要检查可达 lag。

阅卷视角：这些表述能避免失分

模型识别请写 “suggests / tentative”，不要写 “proves / only possible model”；**残差检验**请写 “fail to reject”，不要写 “accept H_0 as true”；**机器学习效果**请写 “test/validation performance”，不要把训练 MSE 当泛化保证；**神经网络**注意 learned parameters 与手动设定的 hyperparameters 不同；**时间预测**注意严格按时间顺序划分训练/测试，避免未来数据泄漏。

9 Original Practice Questions / 原创练习题

Independent exercises / 独立编写练习

These are newly written conceptual questions for independent practice, **not** official NUS quiz questions. 以下为独立编写的概念练习，**并非** NUS 官方试题。

Exercise 1: Two-step smoothing / 两次平滑更新

A sensor has initial level $L_0 = 100$ and $\alpha = 0.2$. The next readings are 110 and 90. Compute L_2 and the SES forecast three periods after time 2. / 求第二期水平与其后三步预测。**Answer / 答案：** $L_1 = 102$, $L_2 = 0.8(102) + 0.2(90) = 99.6$. Without a trend component, $\hat{y}_{5|2} = 99.6$.

Exercise 2: Attention allocation / 注意力分配

Two allowed attention logits are 0 and $\log 3$, with values 4 and 12. Compute the softmax weights and weighted value. / 求权重与加权输出。**Answer / 答案：** Weights are $(1/4, 3/4)$; output is $4/4 + 36/4 = 10$. / 权重归一化后输出为 10。

Exercise 3: Gate arithmetic / 门控计算

A scalar cell has $c_{t-1} = 2$, $f_t = 0.9$, $i_t = 0.25$, and $\tilde{c}_t = -0.4$. Find c_t. Does this determine h_t? / 计算新细胞状态；能否据此确定隐状态？**Answer / 答案：** $c_t = 0.9(2) + 0.25(-0.4) = 1.7$. The output gate is still needed to obtain $h_t = o_t \tanh(c_t)$. / 仍需输出门。

Exercise 4: Receptive field / 感受野

A causal convolution stack has one convolution per layer, kernel size 3, stride 1, and dilations 1, 2, 4. How many time positions lie in its receptive field? / 求感受野大小。**Answer / 答案：** $R = 1 + (3-1)(1+2+4) = 15$, covering the current input and the preceding 14 positions. / 包含当前与之前 14 个位置。

Exercise 5: Seasonal reconstruction / 季节还原

Let $z_t = y_t - y_{t-12}$. At time n, $y_{n-11} = 80$ and $\hat{z}_{n+1|n} = 5$. Obtain $\hat{y}_{n+1|n}$ and identify the historical value needed for the following month. / 求下一月预测及再下一月所需历史值。**Answer / 答案：** $\hat{y}_{n+1|n} = 85$; the next month uses y_{n-10}. / 季节差分还原需对齐去年同月。

Exercise 6: Model diagnostics / 模型诊断

Two models use the same training data and likelihood convention. Model A has AIC 120 and residual Ljung–Box $p = 0.002$; B has AIC 123 and $p = 0.40$. Is choosing A solely by AIC well justified? / 只按 AIC 选择 A 是否充分？**Answer / 答案：** No. A has lower AIC but evidence of remaining residual autocorrelation. Investigate its specification and compare chronological validation performance; B's larger p does not prove correctness. / 应结合诊断与时间顺序验证。

Exercise 7: Validation leakage / 验证泄漏

A forecaster standardizes an entire series before separating its final 20 observations for validation. Which information has leaked, and how should the pipeline change? / 泄漏在哪里，如何修正？**Answer / 答案：** Validation observations influenced the mean and standard deviation. Fit preprocessing on each training window and apply those fitted parameters to its validation window. / 预处理参数只由训练窗口估计。

Exercise 8: Diminishing lag weights / 滞后权重衰减

A scalar linear recurrence has $W = -0.5$. If the coefficient of the current observation in its unfolded forecast is 0.8, find the next three lag coefficients. / 求之后三个滞后系数。**Answer / 答案：** $-0.4,\ 0.2,\ -0.1$. The ratio is W, giving alternating signs and geometric decay. / 符号交替且按几何级数衰减。

Exercise 9: Interval interpretation / 区间解释

Two intervals for the same regression at the same future time use factors $s\sqrt{h_*}$ and $s\sqrt{1+h_*}$. Which should be used for a new observation, and why is it wider? / 哪个用于新观测，为什么更宽？ **Answer / 答案：** Use $s\sqrt{1+h_*}$; it includes new-observation noise as well as uncertainty in the fitted mean. / 多出的 **1** 对应新观测误差。

Exercise 10: Differencing expansion / 差分展开

For quarterly observations, expand $(1-B)(1-B^4)y_t$ and state the information required to reconstruct y_t from this difference. / 展开并说明还原所需历史值。**Answer / 答案：** $y_t - y_{t-1} - y_{t-4} + y_{t-5}$. Reconstruction adds $y_{t-1} + y_{t-4} - y_{t-5}$ to the difference. / 需对齐三个历史时点。

附录：Lecture 7–12 英文术语考前速查表

使用方法：先看英文识别题干，再看中文含义；粗体词是常见判断题的关键词。此表按讲义章节归类，不代表所有词都必须逐字背诵。

A. Lecture 7：时间回归与诊断

English	中文	考试中看到它应想到什么
Regression on time	时间趋势回归	用时间 t 解释 y_t
Trend / linear trend	趋势 / 线性趋势	$\beta_0 + \beta_1 t$
Deterministic trend	确定性趋势	固定函数描述趋势
Seasonality / seasonal pattern	季节性 / 季节模式	固定周期重复
Seasonal dummy / indicator	季节虚拟变量	0–1 变量；避免完全共线
Reference category	基准类别	被省略的虚拟变量类别
Fourier terms / harmonics	傅里叶项 / 谐波	sin, cos 表达周期
Residual / fitted value	残差 / 拟合值	$e_t = y_t - \hat{y}_t$
Autocorrelation / serial correlation	自相关 / 序列相关	相邻误差可能相关
Durbin–Watson statistic	DW 统计量	约 2 无一阶相关；小于 2 提示正相关
Homoscedasticity	同方差性	误差方差稳定
Heteroscedasticity	异方差性	方差随水平或时间变化
Prediction interval	预测区间	单个未来观测的不确定性
Confidence interval	置信区间	参数 / 均值估计的不确定性
Out-of-sample / holdout	样本外 / 留出集	真正检验预测能力
Exponential growth	指数增长	常用对数线性化
Log transformation	对数变换	稳定乘法性波动

B. Lecture 8：指数平滑

English	中文	识别提示
Simple exponential smoothing (SES)	简单指数平滑	水平项；α
Smoothing constant / parameter	平滑系数 / 参数	通常 $0 \le \alpha \le 1$
Level / level component	水平 / 水平分量	L_t
Trend component / slope	趋势分量 / 斜率	Holt 的 T_t
Holt's linear method	Holt 线性趋势法	水平＋趋势
Damped trend	阻尼趋势	长期趋势逐渐减弱
Holt–Winters	Holt–Winters 方法	水平＋趋势＋季节
Additive seasonality	加法季节性	季节波动幅度近似固定
Multiplicative seasonality	乘法季节性	波动随水平按比例变化
Initialization	初始值设定	初始 level、trend、season
One-step-ahead forecast	一步预测	$\hat{y}_{t+1\|t}$
Forecast horizon	预测步长	向前预测 h 期
Sum of squared errors (SSE)	误差平方和	$\sum e_t^2$
Root mean squared error (RMSE)	均方根误差	大误差惩罚更重
Mean absolute percentage error (MAPE)	平均绝对百分比误差	接近零的实际值需谨慎

C. Lecture 9：ARMA 与识图（高优先级）

English	中文	识别提示
Autocorrelation function (ACF)	**自相关函数**	**MA 看 ACF 截尾**
Partial autocorrelation function (PACF)	**偏自相关函数**	**AR 看 PACF 截尾**
Sample ACF (SAC)	样本自相关	图中常见 SAC
Sample PACF (SPAC)	样本偏自相关	图中常见 SPAC
Cut off / cutoff	**截尾**	某 lag 后理论相关为零
Tail off / die down	**拖尾 / 逐渐衰减**	可指数衰减或振荡衰减
Lag / lag order	滞后 / 滞后阶数	lag 3 指三期以前
Spike / significant spike	尖峰 / 显著尖峰	超出置信带需关注
Confidence band	置信带	样本显著性参考界线
Damped oscillation	阻尼振荡	正负交替、幅度缩小
Autoregressive (AR)	自回归	过去观测值
Moving average (MA)	移动平均模型	过去随机冲击，非普通滑动均值
ARMA	自回归移动平均	ACF/PACF 通常都拖尾
White noise / innovation	白噪声 / 新冲击	无时间相关的误差
Stationarity / stationary	平稳性 / 平稳的	均值、方差、自协方差结构稳定
Causality / causal AR	因果性 / 因果 AR	AR 根在单位圆外
Invertibility / invertible MA	可逆性 / 可逆 MA	MA 根在单位圆外
Characteristic root	特征根	检查单位圆位置
Backshift operator	后移算子	$By_t = y_{t-1}$

D. Lecture 10：ARIMA、SARIMA 与检验（高优先级）

English	中文	识别提示
Integrated / integration order	单整 / 差分阶数	ARIMA 中的 d
Differencing	**差分**	$(1-B)^d y_t$
Seasonal differencing	**季节差分**	$(1-B^L)^D y_t$
First / second difference	一阶 / 二阶差分	$y_t - y_{t-1}$；再差一次
Over-differencing	过度差分	不必要的负相关
Unit root	单位根	随机游走常见
Random walk / drift	随机游走 / 漂移	$y_t = y_{t-1} + \delta + \epsilon_t$
Augmented Dickey–Fuller (ADF)	扩展 Dickey–Fuller 检验	原假设：单位根
KPSS test	KPSS 检验	原假设：平稳
Seasonal period	**季节周期**	月度常见 $L = 12$
Seasonal AR (SAR)	季节自回归	季节 PACF 截尾
Seasonal MA (SMA)	季节移动平均	季节 ACF 截尾
Ljung–Box test	**Ljung–Box 检验**	原假设：无残差自相关
Null hypothesis (H_0)	原假设	小 p 值拒绝
Reject / fail to reject	拒绝 / 未能拒绝	不等于证明原假设为真
Adequate / inadequate	充分 / 不充分	模型是否捕捉相关结构
Maximum likelihood (MLE)	极大似然估计	使似然最大
Akaike information criterion (AIC)	赤池信息准则	同类数据比较，越小越好
Bayesian information criterion (BIC)	贝叶斯信息准则	惩罚复杂度，越小越好
Residual diagnostics	残差诊断	残差 ACF、检验、Q–Q 图
Back-transformation	逆变换	从 log 尺度还原
Regression with ARMA errors	带 ARMA 误差的回归	回归解释均值，ARMA 解释误差

E. Lecture 11：神经网络、RNN、LSTM

English	中文	识别提示
Feed-forward neural network	前馈神经网络	无循环状态
Neural network autoregression (NNAR)	神经网络自回归	固定滞后窗口作输入
Hidden layer / hidden units	隐藏层 / 隐藏单元	不是预测步长
Activation / identity activation	激活函数 / 恒等激活	恒等激活使 NNAR 退化为线性 AR
Tanh / sigmoid	双曲正切 / S 形函数	门控和梯度
Recurrent neural network (RNN)	循环神经网络	状态携带过去信息
Hidden state / cell state	隐状态 / 细胞状态	h_t 与 c_t 不同
Backpropagation through time (BPTT)	时间反向传播	跨多个时间步求梯度
Vanishing gradient	**梯度消失**	多个小于 1 的因子连乘
Exploding gradient / clipping	梯度爆炸 / 梯度裁剪	连乘放大；裁剪控制幅度
Long short-term memory (LSTM)	长短期记忆网络	细胞状态与门控
Forget gate	**遗忘门**	$f_t \approx 1$ 保留旧信息
Input gate / output gate	输入门 / 输出门	写入候选值 / 输出状态
Candidate cell state	候选细胞状态	$\tilde{c}_t$
Gated recurrent unit (GRU)	门控循环单元	更新门、重置门
Update gate	**更新门**	类比 SES 的 α
Error-correction form	误差修正形式	旧值＋步长 ×(目标 - 旧值)
Linear RNN	线性循环网络	滞后权重 VW^kU
Finite window / infinite AR	有限窗口 / 无限阶 AR	可逆 MA 可写成 AR(∞)
Covariate / exogenous variable	协变量 / 外生变量	可用于补充预测信息

F. Lecture 12：序列网络、注意力与 Transformer

English	中文	识别提示
Temporal convolutional network (TCN)	时间卷积网络	因果卷积、扩张卷积
Causal convolution	因果卷积	不使用未来信息
Dilated convolution	扩张卷积	增大感受野
Receptive field	感受野	网络能看到的历史范围
Sequence-to-sequence (Seq2Seq)	序列到序列	编码器 / 解码器
Encoder / decoder	编码器 / 解码器	输入表征 / 生成预测
Attention mechanism	注意力机制	按相关性分配权重
Query / key / value (Q/K/V)	查询 / 键 / 值	匹配分数与加权求和
Scaled dot-product attention	缩放点积注意力	$\mathrm{softmax}(QK^\top/\sqrt{d_k})V$
Self-attention	自注意力	同一序列内部的信息交互
Multi-head attention	多头注意力	不同子空间并行关注
Positional encoding	位置编码	注入顺序信息
Mask / causal mask	掩码 / 因果掩码	防止偷看未来
Transformer	Transformer 架构	注意力＋前馈层等
DLinear	分解线性预测模型	趋势 / 季节分解后线性预测
PatchTST / patch	PatchTST / 片段	将时间序列切成 patch
Data leakage	数据泄漏	使用了预测时不可得的信息
Rolling-origin evaluation	滚动起点评估	时间顺序验证

G. 英文题干高频动词与陷阱表达

题干表达	看到后立即理解为
Which statement **best describes** ...?	哪个选项**最准确地描述**……?
What is the **most likely explanation**?	最可能的原因是什么?
What is the **appropriate conclusion**?	应当得出什么结论?
Which model is it **equivalent to**?	它等价于哪一种模型?
Exactly / approximately	精确地 / 近似地（有限窗口常只能近似）
Only / always / must	唯一 / 总是 / 必须：警惕过度绝对化
In general / typically	一般情况下 / 通常（允许例外）
After training / test residuals	训练之后 / 测试集残差（不是训练损失）
One-step ahead / k steps back	向前预测一步 / 回看 k 个时间步
With respect to	关于……求导 / 相对于……
Shrinks geometrically	按几何级数缩小（梯度消失）
Captures all dependence	已捕获全部依赖结构（需要残差检验支持）
Remedy / consider	补救方法 / 可以考虑（通常不止一种）
Collapses to / reduces to	退化为 / 化简为某个经典模型
Truncates / finite window	截断 / 有限窗口
Put weight on	给某个滞后观测赋予多大权重
Keep long memory	保留长期记忆

考前英语读题：六个最容易混淆的点

1. **Residuals are autocorrelated** = 残差仍有自相关，通常提示模型未充分解释时间依赖；不是“模型拟合得好”。
2. **Small Ljung–Box p-value** = 拒绝“残差无自相关”的原假设；不要与 ADF/KPSS 的原假设混淆。
3. **Forget gate near one** = 保留旧状态；**near zero** 才是强烈遗忘。
4. **Update gate** 在题目给出的 GRU 误差修正写法中对应 SES 的 α；不同教材门的符号约定可能不同。
5. **Identity activation** = 不引入非线性；多隐藏单元也无法让线性 NNAR 变成非线性。
6. **Seasonal lag 12**（月度数据）= 去年同月；**lag 1** = 上个月。AR 看 PACF，MA 看 ACF。

最后 3 分钟：英语关键词 ⟶ 解题动作

cuts off / dies down → 先判 AR/MA；**seasonal lag** → 查 $L, 2L$；**Ljung–Box** → 看残差相关；**vanishing gradient** → 看雅可比连乘；**forget gate** → 看保留旧状态；**linear RNN** → 算 VW^kU；**identity** → 线性 AR；**update gate** → 类比平滑系数；**causal mask** → 不允许看未来。